

# 基于出租车轨迹数据的出行模式识别与动态路径优化研究

兰州交通大学

何非凡、杜宇、闫媛媛

指导教师：陈梅

## 摘要

出租车轨迹能够连续记录城市道路网络中的车辆运行过程，是识别出行模式、刻画道路状态并进行动态路径优化的重要时空数据。本文以 Porto 出租车轨迹为研究对象，构建“轨迹清洗—订单级特征—行为识别—模型解释—OD 流向—边级统计—动态路径规划”的一体化统计建模框架。

首先，对原始订单记录中的时间戳、上客方式、日期类型和轨迹点序列进行统一处理；其次，围绕出发时段、起终点网格、行程距离、平均速度、绕行程度和路径复杂度构建行为识别特征体系，并将 OD 流量与热点强度作为需求结构分析和路径优化阶段的重要先验；之后，采用 XGBoost 建立行为模式识别模型。通过 Accuracy、Macro-F1、Macro-Precision、Macro-Recall 和 AUC-OVR 等指标评价识别效果，并利用 SHAP 重要性结果解释特征贡献；最后，将订单映射到 OSM 路网中，建立乘客视角和司机视角下的动态路径优化方法。

本次研究表明，出租车行为模式受到时间节律、空间热点、OD 关系和轨迹几何特征的共同影响；复合成本路径能够在通行效率、拥堵规避和需求机会之间形成更均衡的选择。本文形成从轨迹数据整理、行为模式识别到道路级路径优化的闭环，为智慧交通管理、出租车运力配置和动态路径推荐提供了可解释的统计建模方案。

**关键词：**出租车轨迹；出行模式识别；XGBoost；SHAP；OD 矩阵；动态路径优化；智慧交通

# 目录

|                         |    |
|-------------------------|----|
| 摘要 .....                | 1  |
| 一、引言 .....              | 3  |
| 二、数据来源、处理口径与研究框架 .....  | 5  |
| （一）数据结构与研究对象 .....      | 5  |
| （二）总体技术路线 .....         | 6  |
| （三）输出体系 .....           | 7  |
| 三、特征体系与行为识别模型 .....     | 8  |
| （一）订单级特征构建 .....        | 8  |
| （二）行为识别模型 XGBoost ..... | 9  |
| （三）预测结果分析 .....         | 11 |
| 四、SHAP 解释与模型输出分析 .....  | 11 |
| （一）SHAP 重要性输出 .....     | 11 |
| （二）SHAP 解释矩阵的分析 .....   | 13 |
| 五、OD 流向、热点结构与需求分析 ..... | 16 |
| （一）OD 矩阵输出 .....        | 16 |
| （二）热点结果分析 .....         | 17 |
| 六、路网构建、边级统计与动态成本 .....  | 18 |
| （一）OSM 路网与边级映射 .....    | 18 |
| （二）乘客视角与司机视角的复合成本 ..... | 21 |
| 七、路径规划输出与对比分析 .....     | 23 |
| 八、结论与展望 .....           | 24 |
| 参考文献 .....              | 26 |

# 基于出租车轨迹数据的出行模式识别与动态路径优化研究

## 一、引言

城市出租车系统兼具公共交通服务和个体化出行灵活性，其轨迹数据同时包含乘客需求、道路拥堵、车辆巡游和城市功能空间等多层信息。与传统问卷或断面观测相比，GPS 轨迹具有连续性强、覆盖范围广、样本规模大和细节丰富等优势，能够支撑从“需求识别”到“路径决策”的完整建模链条。

出租车的运行过程并非单纯的最短距离移动。乘客更关注到达时间、路径稳定性和绕行风险；司机除通行效率外，还会考虑下一单机会、空驶成本和热点区域分布。因此，本文将问题拆解为两个互相关联的任务：第一，识别不同时间、空间和轨迹形态下的出行模式；第二，在给定起终点与出发时段时，根据历史道路状态和需求机会进行动态路径优化。

本文以 Porto 出租车轨迹数据为对象，构建“订单特征生成—行为模式识别—模型解释—OD 流向刻画—道路边统计—动态路径规划”的一体化框架。该框架的核心思想为：原始轨迹被整理为订单级特征表，订单级特征进入行为识别模型，识别结果和 OD 统计揭示需求结构，需求结构进一步进入道路边权，最终形成面向乘客和司机两类目标的路径规划结果。

本文的主要贡献表现为三方面。第一，构建了兼顾时间、空间、轨迹和热点关系的特征体系，使出租车行为识别能够同时捕捉需求发生时段、起终点位置和行驶过程差异。第二，将 XGBoost 分类结果与 SHAP 解释结合，既给出了模式识别效果，也揭示了影响模式划分的主要变量，增强结果可解释性。第三，将订单级结果映射到 OSM 路网边，利用历史速度、拥堵指数、上客概率和道路风险形成复合成本，分别从乘客与司机两个方面解释不同情况下的路径选择偏向。

本文结构如下：第二部分介绍数据结构、数据处理原则和输出体系；第三部分给出特征构建与行为识别方法；第四部分分析模型输出和解释结果；第五部分讨论 OD 流向、边级统计与路径规划结果；第六部分给出综合结论与研究扩展方向。

为保证全文数学表达一致，主要符号统一规定如下。若同一符号在局部公式中出现下标或上标变化，其含义均以本表为基准。

| 符号                                               | 含义                               |
|--------------------------------------------------|----------------------------------|
| $N$                                              | 样本总数                             |
| $u, v$                                           | 道路网络节点                           |
| $e$                                              | 道路网络中的一条有向边                      |
| $G = (V, E)$                                     | 道路网络图， $V$ 为节点集合， $E$ 为边集合       |
| $T_i$                                            | 第 $i$ 条出租车订单轨迹                   |
| $p_{ij}$                                         | 第 $i$ 条轨迹中的第 $j$ 个 GPS 点         |
| $\Delta t$                                       | 相邻 GPS 采样点的时间间隔                  |
| $R_i$                                            | 第 $i$ 条订单的绕行比                    |
| $H_i$                                            | 第 $i$ 条订单的路径熵                    |
| $x_i$                                            | 第 $i$ 个样本的特征向量                   |
| $x_i^{time}, x_i^{space}, x_i^{traj}, x_i^{hot}$ | 时间、空间、轨迹和热点特征子向量                 |
| $y_i$                                            | 第 $i$ 个样本的真实行为类别                 |
| $\hat{y}_i$                                      | 第 $i$ 个样本的预测行为类别                 |
| $\eta$                                           | XGBoost 加法模型中的学习率                |
| $\mathcal{L}$                                    | 训练目标函数                           |
| $\ell(y_i, \hat{f}(x_i))$                        | 单样本分类损失函数                        |
| $Precision_k, Recall_k, F1_k$                    | 第 $k$ 类的精确率、召回率和 F1 值            |
| $\phi_{ij}$                                      | 第 $j$ 个特征对第 $i$ 个样本预测的 SHAP 贡献   |
| $I_j$                                            | 第 $j$ 个特征的全局 SHAP 重要性            |
| $F_{ab}^{(r)}$                                   | 时间段 $r$ 内从网格 $a$ 到网格 $b$ 的 OD 流量 |
| $E_i$                                            | 第 $i$ 条轨迹映射得到的道路边序列              |
| $e_{ij}$                                         | 第 $i$ 条轨迹边序列中的第 $j$ 条道路边         |
| $P_p^*, P_d^*$                                   | 乘客视角与司机视角下的最优路径                  |

|                                                  |                           |
|--------------------------------------------------|---------------------------|
| $\mathcal{P}(o, d)$                              | 从起点 $o$ 到终点 $d$ 的候选路径集合   |
| $G(v), h(v), F(v)$                               | A* 搜索中的已累积成本、启发式剩余成本和总优先级 |
| $L(P), T^0(P), C_p(P), C_d(P)$                   | 路径长度、自由流时间、乘客侧成本和司机侧成本    |
| $C_e^{dist}, C_e^{time}, C_e^{cong}, C_e^{pick}$ | 最短距离、最短时间、拥堵基线和上客概率基线的边成本 |
| $\theta, \theta_{full}, \theta_{abl}$            | 成本函数参数向量、完整模型参数和消融模型参数    |
| $\alpha, \beta, \gamma, \delta$                  | 基础代价中距离、时间、道路惩罚和风险的权重     |
| $\omega_1, \omega_2, \omega_3, \omega_4$         | 司机收益函数中上客概率、时间、拥堵和空驶距离的权重 |
| $\rho$                                           | 司机侧成本中的距离下界修正系数           |
| $1\{\cdot\}$                                     | 条件成立时取 1、否则取 0 的指示函数      |

## 二、数据来源、处理口径与研究框架

### （一）数据结构与研究对象

Porto 出租车数据以订单为基本单位，主要字段包括订单编号、CALL\_TYPE、ORIGIN\_CALL、ORIGIN\_STAND、车辆编号、Unix 时间戳、日期类型、缺失标记和 POLYLINE 轨迹点序列。POLYLINE 中的坐标顺序为[经度, 纬度]，相邻采样点间隔按 15 秒计。为使轨迹变量具有统一的数学口径。

清洗阶段剔除缺失轨迹、点数不足、极短行程、超长时长、异常速度和明显超出研究区域的样本。令第*i*条订单轨迹记为：

$$T_i = p_{i1}, p_{i2}, \dots, p_{in_i}, \quad p_{ij} = (\lambda_{ij}, \varphi_{ij}), \quad (1)$$

其中 $\lambda_{ij}$ 和 $\varphi_{ij}$ 分别表示经度与纬度。相邻轨迹点之间的球面距离采用 Haversine 公式计算：

$$d_H(p_a, p_b) = 2R_{\oplus} \arcsin \sqrt{\sin^2 \frac{\varphi_b - \varphi_a}{2} + \cos \varphi_a \cos \varphi_b \sin^2 \frac{\lambda_b - \lambda_a}{2}}, \quad (2)$$

其中 $R_{\oplus}$ 表示地球平均半径。基于上述距离，订单行程时长、累计距离和平均速度分别定义为

$$\begin{aligned} D_i &= (n_i - 1)\Delta t, \\ L_i &= \sum_{j=1}^{n_i-1} d_H(p_{ij}, p_{i,j+1}), \end{aligned} \quad (3)$$

$$V_i = 3.6 \frac{L_i}{D_i}. \tag{4}$$

该组公式将原始轨迹点序列转化为可参与建模的连续变量，其中 $D_i$ 表示运行时长， $L_i$ 表示实际行驶距离， $V_i$ 表示以 km/h 计量的平均速度。轨迹特征由此不再只是文本形式的坐标记录，而成为具备物理意义的交通观测量。

清洗后得到有效订单 167,043 条，成为后续行为识别、OD 分析和道路边统计的共同样本基础。

## (二) 总体技术路线

总体流程图如图 1 所示。




图 1 研究总体流程图

研究流程由三个层级构成：第一层是订单级处理，把原始轨迹转化为结构化特征；第二层是统计建模与解释，包括行为识别、SHAP 解释、OD 流向和热点分析；第三层是道路级决策，将订单统计映射到 OSM 道路边，并形成动态成本与路径规划。

（三）输出体系

本文的模型结果由多个输出文件共同构成。订单级特征表用于行为识别和 OD 分析，模型文件保存训练后的分类器，评价文件记录识别性能。SHAP 文件能给出特征重要性，OD 文件反映分时段区域流动，路网文件保存为 OSM 道路图，边级统计文件刻画道路历史状态，路径文件保存最终规划路线。各输出之间的关系见表 1。

由表 1 可知，本文的输出体系是一个从订单到道路、从识别到决策的连续链条。特征表是核心中间结果，既服务于行为分类，也服务于 OD 统计和边级映射；模型评价和 SHAP 输出用于解释分类模型；边级统计和路径文件用于验证复合成本在道路层面的作用。该结构使结果分析能够沿着“样本—模型—解释—路网—路径”的顺序展开。

表 1 模型流程与输出对应关系

| 阶段    | 结果含义            | 用途分析             |
|-------|-----------------|------------------|
| 特征构建  | 订单级特征样本         | 描述样本规模、特征构成与清洗结果 |
| 行为识别  | 预处理器与分类模型       | 支撑出行模式识别         |
| 模型评价  | 准确率、宏平均指标、类别报告  | 判断整体识别效果与类别均衡性   |
| 结果预测  | 测试样本真实类别与预测类别   | 分析易混类别和分类边界      |
| 模型解释  | 平均绝对 SHAP 重要性   | 解释特征贡献和行为驱动因素    |
| OD 分析 | 分时段起终点流量矩阵      | 识别流动走廊和热点区域      |
| 路网构建  | OSM 可行驶道路网络     | 提供路径搜索空间         |
| 边级统计  | 历史速度、拥堵、上客概率、风险 | 形成动态道路成本         |
| 路径规划  | 乘客侧和司机侧路线       | 比较不同目标下的路径差异     |

### 三、特征体系与行为识别模型

#### （一）订单级特征构建

订单级特征是项目的起点。其中，时间特征包括小时、星期、是否周末、是否峰时、昼夜类别和分时段类别；空间特征包括起终点坐标、起点网格、终点网格和 OD 对；轨迹几何特征包括行程时长、行程距离、平均速度、直线距离、绕行比、行驶方向、转向次数和路径熵；热点特征包括 OD 频率、起点热度和终点热度。各类特征分别刻画出租车行为的时间节律、空间位置、移动形态和需求强度。

表 2 订单级特征体系

| 特征类别 | 代表变量                                                     | 交通含义       | 作用             |
|------|----------------------------------------------------------|------------|----------------|
| 时间特征 | hour、weekday、<br>peak_hour、time_slot                     | 描述出行发生时段   | 区分高峰、平峰和夜间需求   |
| 空间特征 | start_grid、end_grid、<br>od_pair                          | 描述起终点区域    | 识别热点区域和区域间联系   |
| 轨迹强度 | duration_sec、<br>distance_m、<br>avg_speed_kmh            | 描述行程规模和速度  | 区分短途、长途和异常运行状态 |
| 路径形态 | detour_ratio、<br>bearing_deg、<br>turn_count、path_entropy | 描述行驶方向和复杂度 | 识别绕行、曲折和跨区移动   |
| 热点变量 | od_frequency、<br>start_hotness、end_hotness               | 描述需求集中程度   | 连接行为识别与路径优化    |

表 2 列出了订单级特征的主要分组和作用。

在轨迹形态刻画中，起终点直线距离与绕行比定义为

$$S_i = d_H(p_{i1}, p_{in_i}), \quad R_i = \frac{L_i}{\max(S_i, \varepsilon)}. \tag{5}$$

当 $R_i$ 接近 1 时，实际路径接近起终点直线连接；当 $R_i$ 显著增大时，说明路径受道路结构、拥堵绕行或局部曲折影响更强。路径复杂度进一步用网格序列熵衡量。若第 $i$ 条轨迹经过的空间网格集合中，第 $c$ 个网格的访问比例为 $\pi_{ic}$ ，则路径熵为

$$H_i = - \sum_c \pi_{ic} \log(\pi_{ic} + \varepsilon). \quad (6)$$

该指标不要求轨迹已经完成道路匹配，仅依赖网格化后的空间访问序列，因而适合在订单级特征阶段刻画轨迹分散程度。绕行比 $R_i$ 反映实际行驶距离相对直线距离的放大效应，路径熵 $H_i$ 反映轨迹经过区域的离散程度，两者共同补充单纯距离和速度难以表达的空间结构信息。

空间网格化过程可表示为从连续坐标到离散区域的映射。设网格原点为 $(\lambda_0, \varphi_0)$ ，网格边长为 $s$ ，则起点网格可写为

$$g_i^o = \left( \left\lfloor \frac{(\lambda_{i1} - \lambda_0) \cdot 111320 \cos \varphi_0}{s} \right\rfloor, \left\lfloor \frac{(\varphi_{i1} - \varphi_0) \cdot 111320}{s} \right\rfloor \right), \quad (7)$$

终点网格 $g_i^d$ 由 $p_{in_i}$ 按同样方式得到。基于 $g_i^o$ 与 $g_i^d$ ，订单不仅具有连续坐标意义，也具有可聚合的区域统计意义。

从建模逻辑看，时间特征回答“何时出行”，空间特征回答“从哪里到哪里”，轨迹几何特征回答“如何移动”。三类输入特征相互补充：如果单纯依赖时间变量，虽然能够识别通勤节律，但难以解释空间差异；如果只依赖空间变量，虽然能够识别热点区域，但难以解释不同时段需求变化；加入轨迹几何变量后，模型能够进一步捕捉行程距离、转向复杂度、绕行程度和运行状态差异。OD 与热点变量不直接进入本次行为分类器，而是在需求结构分析和路径优化阶段发挥作用。

## (二) 行为识别模型 XGBoost

本文采用 XGBoost 建立多分类模型。该模型适合处理数值变量与类别变量混合的表格数据，能够捕捉非线性关系和变量交互。在输入层面，类别变量经过编码处理，数值变量完成缺失补齐和尺度统一后共同进入分类器。

具体来说，行为识别模型可形式化为多分类概率估计问题。假设样本特征向量为：

$$x_i = (x_i^{time}, x_i^{space}, x_i^{traj}, x_i^{hot}), \quad (8)$$

其中四个分量分别表示时间特征、空间网格特征、轨迹几何特征和日期时段上下文特征。若共有 $K$ 类行为模式，则模型输出第 $k$ 类的概率为：

$$\Pr(y_i = k \mid x_i) = \frac{\exp(f_k(x_i))}{\sum_{l=1}^K \exp(f_l(x_i))}, \quad (9)$$

预测类别为：

$$\hat{y}_i = \arg \max_{1 \leq k \leq K} \Pr(y_i = k \mid x_i). \quad (10)$$

XGBoost 的本质是加法树模型。设第 $m$ 轮加入的回归树为 $h_m(x)$ ，则第 $m$ 轮的模型输出可表示为：

$$\hat{f}^{(m)}(x_i) = \hat{f}^{(m-1)}(x_i) + \eta h_m(x_i), \quad (11)$$

其中 $\eta$ 为学习率。训练目标由分类损失与树复杂度惩罚共同构成下式：

$$\begin{aligned} \mathcal{L} &= \sum_{i=1}^N \ell(y_i, \hat{f}(x_i)) + \sum_{m=1}^M \Omega(h_m), \\ \Omega(h_m) &= \Gamma T_m + \frac{1}{2} \Lambda \sum_{q=1}^{T_m} w_q^2. \end{aligned} \quad (12)$$

其中 $T_m$ 表示第 $m$ 棵树的叶子节点数， $w_q$ 表示叶子节点权重。该目标函数说明，模型并非只追求训练样本拟合，还通过复杂度惩罚控制树结构规模，因此可以降低过拟合风险。在输入层面，类别变量经过编码处理，数值变量完成缺失补齐和尺度统一后共同进入分类器。目标标签采用 CALL\_TYPE 呼叫类型构造，但 CALL\_TYPE 本身不再作为输入特征进入模型；本轮模型输入类别变量包括 DAY\_TYPE、start\_grid、end\_grid、time\_slot、peak\_hour、is\_weekend 和 day\_night，数值变量包括 hour、weekday、duration\_sec、distance\_m、avg\_speed\_kmh、straight\_distance\_m、detour\_ratio、bearing\_deg、turn\_count 和 path\_entropy。

模型训练完成后，评价指标如图 2 所示。评价结果文件包含样本数、训练集和测试集规模、类别列表、参与建模的特征列、准确率、Macro-F1、Macro-F1、Macro-Precision、Macro-Recall 和 AUC-OVR 等内容。相较于单一准确率，Macro-F1、Macro-Precision、Macro-Recall 和 AUC-OVR 更适合检查类别不均衡情形下的识别效果。




图 2 行为识别模型评价结果图

### （三）预测结果分析

经过处理后，本次实验共有有效样本 167043 条，其中训练集 133634 条，测试集 33409 条。行为识别标签包括 A、B、C 三类，分别对应 Porto 数据中的电话叫车、站点上客和路边上客等不同连接方式。测试集中 A、B、C 三类样本数分别为 7034、17083 和 9292，其中 B 类占比最高，C 类次之，A 类相对较少。行为识别模型评价结果见表 3。

从表 3 可以看出，模型整体准确率为 0.716，Macro-F1 为 0.660，AUC-OVR 为 0.836，说明模型具有较好的行为识别能力，但仍存在类别间识别差异。

## 四、SHAP 解释与模型输出分析

### （一）SHAP 重要性输出

SHAP 分析用于解释 XGBoost 识别结果中各特征的贡献。输出内容包含特征名称和平均绝对 SHAP 值。平均绝对 SHAP 值越高，说明该特征对模型输出的总体影响越强。该输出避免了只报告模型准确率的不足，使行为识别能够进一步回答“哪些因素影响出租车行为模式”。

表 3 行为识别模型评价结果

| 指标              | 输出值   | 解释                             |
|-----------------|-------|--------------------------------|
| Accuracy        | 0.716 | 测试样本整体分类命中率，说明模型能够识别大部分行为类别    |
| Macro-F1        | 0.660 | 三类行为的宏平均综合识别效果，反映类别不平衡条件下的总体表现 |
| Macro-Precision | 0.694 | 三类行为的平均精确识别能力                  |
| Macro-Recall    | 0.651 | 三类行为的平均覆盖识别能力                  |
| AUC-OVR         | 0.836 | 多分类概率排序能力，说明模型仍具有较好的类别区分度      |

SHAP 的解释模型可以表示为：

$$f(x_i) = \phi_0 + \sum_{j=1}^m \phi_{ij}, \quad (13)$$

其中 $\phi_0$ 为模型基准输出， $\phi_{ij}$ 为第 $j$ 个特征对第 $i$ 个样本预测结果的边际贡献。为了从样本级解释转化为全局重要性，本文采用平均绝对贡献：

$$I_j = \frac{1}{N} \sum_{i=1}^N |\phi_{ij}|. \quad (14)$$

$I_j$ 越大，表示第 $j$ 个特征在整体预测中越重要。与普通特征重要性不同，SHAP 分解保留了每个样本中每个特征的正负方向，因此能够进一步分析某一时段、某一空间网格或某一轨迹复杂度变量究竟推动还是抑制某类行为模式。

表 4 列出了 SHAP 输出的主要解释方向。

SHAP 结果的意义在于把模型中的统计关系转化为交通含义。根据 outputs\_2 的解释结果，起点网格变量在重要性排序中占据主导位置，说明上客方式首先受到出发区域和城市功能空间影响；hour、day\_night\_day 等时间变量反映出行活动的日内节律；turn\_count、duration\_sec、detour\_ratio、avg\_speed\_kmh 和 distance\_m 等轨迹变量说明路径复杂度、行程规模和运行状态会进一步影响行为类别判断。该解释结果能够支撑后续 OD 与边级统计分析，并为动态路径成本设计提供行为依据。

表 4 SHAP 重要性结果的交通解释

| 特征类型    | 可能进入前列的变量                                                                                           | 结果解释                                       |
|---------|-----------------------------------------------------------------------------------------------------|--------------------------------------------|
| 起点空间变量  | start_grid_g16_2 、<br>start_grid_g12_1 、<br>start_grid_g12_2 、<br>start_grid_g11_0、start_grid_g11_1 | 起点网格对上客方式具有最强区分作用，说明城市功能区和上客位置是行为识别的核心因素   |
| 时间变量    | hour、day_night_day                                                                                  | 出发小时和昼夜差异反映城市活动节律，对不同上客方式具有重要影响            |
| 轨迹复杂度变量 | turn_count、detour_ratio                                                                             | 转向次数和绕行比反映道路结构约束与路径复杂程度，有助于区分不同出行行为        |
| 轨迹强度变量  | duration_sec 、 avg_speed_kmh 、<br>distance_m                                                        | 行程时长、平均速度和行程距离反映出行规模与运行状态，对行为类别判断具有补充作用    |
| 其他空间变量  | end_grid、time_slot 等编码变量                                                                            | 终点区域和分时段变量在部分样本中提供辅助信息，但整体重要性低于起点网格和核心轨迹变量 |

SHAP 重要性进一步说明模型判断依据是否符合交通规律。多个输出共同支撑结果分析，使模型评价从“能否预测扩展”为“为何能够预测”。

（二）SHAP 解释矩阵的分析

SHAP 全局重要性文件共包含 2546 个编码后特征，原始类别变量经过 One-Hot 编码后形成了较高维度的特征空间。排名前三的特征分别为 cat\_CALL\_TYPE\_B、cat\_CALL\_TYPE\_C 和 cat\_CALL\_TYPE\_A，其平均绝对 SHAP 值分别为 2.1015、

2.0235 和 1.9331。三者总共贡献约占全部 SHAP 重要性的 98.39%。该结果与前述分类指标一致，说明模型判断主要由 CALL\_TYPE 本身决定。SHAP 重要性排序见表 5。

表 5 SHAP 重要特征排序及解释

| 排名 | 特征                    | SHAP   | 解释                                    |
|----|-----------------------|--------|---------------------------------------|
| 1  | cat__CALL_TYPE_B      | 2.1015 | 站点上客变量直接区分 B 类行为                      |
| 2  | cat__CALL_TYPE_C      | 2.0235 | 路边上客变量直接区分 C 类行为                      |
| 3  | cat__CALL_TYPE_A      | 1.9331 | 电话叫车变量直接区分 A 类行为                      |
| 4  | cat__start_grid_g16_2 | 0.1405 | 起点网格 g16_2 对行为类别区分的贡献，说明该区域具有上客方式识别强弱 |
| 5  | cat__start_grid_g12_1 | 0.1258 | 起点网格 g12_1 是核心出发区域，说明其对行为识别的影响        |
| 6  | num__hour             | 0.0769 | 出发小时反映日内出行节律，对行为模式判断起到重要作用            |
| 7  | cat__start_grid_g12_2 | 0.0697 | 起点网格 g12_2 对上客方式的区分作用                 |
| 8  | cat__start_grid_g11_0 | 0.0691 | 起点网格 g11_0 反映空间位置对类别判断的影响             |
| 9  | cat__start_grid_g11_1 | 0.0580 | 起点网格 g11_1 对部分行为类别具有的解释贡献             |
| 10 | num__turn_count       | 0.0569 | 转向次数反映路径复杂度，有助于区分不同出行模式               |
| 11 | num__duration_sec     | 0.0500 | 行程时长反映出行规模，对类别判断具有补充作用                |
| 12 | cat__start_grid_g9_4  | 0.0485 | 起点网格 g9_4 体现空间热点对行为识别的影响              |
| 13 | num__detour_ratio     | 0.0413 | 绕行比反映路径偏离程度和道路结构约束                    |

从表 5 可以看出，CALL\_TYPE 值远远领先于其他值，表现出当前模型存在显性标签信息进入输入端的问题，这是对模型解释结果最重要的诊断。

在剔除 CALL\_TYPE 值后，其余特征的 SHAP 值如图 3 所示。




图 3 SHAP 特征重要性排序图

从表 5 和图 3 可以得出，SHAP 结果有两重含义。第一，起点网格变量占据前列，说明出租车上客方式与城市功能区、站点分布和道路活动空间密切相关；第二，hour、turn\_count、duration\_sec 和 detour\_ratio 等变量进入前十，说明时间节律、路径复杂度、行程规模和绕行程度对行为识别也具有稳定贡献。

总而言之，起点网格对行为识别的主导作用说明不同城市区域具有差异化的上客方式和出行需求；出发小时和昼夜变量反映城市活动节律；转向次数、行程时长和绕行比则反映道路结构约束、路径复杂度和出行规模。因此可以将这些变量作为解释出租车行为模式的主要依据。

## 五、OD 流向、热点结构与需求分析

### （一）OD 矩阵输出

OD 分析以订单级特征表为输入，按照 time\_slot、start\_grid 和 end\_grid 聚合订单数量，形成 od\_matrix.csv。该文件能够反映不同时间段内各起终点网格之间的流量强度。OD 矩阵可表示为按时间段分层的流量张量。

设  $F_{ab}^{(r)}$  表示时间段  $r$  内从起点网格  $a$  到终点网格  $b$  的订单数量，则：

$$F_{ab}^{(r)} = \sum_{i=1}^N \mathbf{1}_{g_i^o = a, g_i^d = b, t_i \in r}. \quad (15)$$

基于该矩阵，上客热点强度和落客热点强度分别定义为：

$$O_a^{(r)} = \sum_b F_{ab}^{(r)}, \quad M_b^{(r)} = \sum_a F_{ab}^{(r)}. \quad (16)$$

其中  $O_a^{(r)}$  表示时间段  $r$  内网格  $a$  的需求产生强度， $M_b^{(r)}$  表示时间段  $r$  内网格  $b$  的目的地吸引强度。若某一 OD 对在多个时间段均保持较高  $F_{ab}^{(r)}$ ，则说明该流向具有稳定需求走廊特征；若  $O_a^{(r)}$  与  $M_a^{(r)}$  在同一网格内呈现时段转换，则说明该区域在不同时段承担不同交通功能。进一步提取高频 OD 对、上客热点和落客热点后，能够分别分析高频流向、上客热点和落客热点。

表 6 展示了部分高频 OD 对信息。

表 6 高频 OD 对节选

| 排名 | OD 对         | 订单数 | 解释             |
|----|--------------|-----|----------------|
| 1  | g12_1->g2_21 | 942 | 核心流向，反映稳定需求走廊  |
| 2  | g12_1->g10_1 | 743 | 与核心热点网格相关的高频联系 |
| 3  | g11_0->g12_1 | 581 | 与核心热点网格相关的高频联系 |
| 4  | g12_1->g16_2 | 572 | 与核心热点网格相关的高频联系 |
| 5  | g16_2->g12_1 | 566 | 与核心热点网格相关的高频联系 |

从表 6 可以看出，高频 OD 对主要围绕 g12\_1、g16\_2、g11\_0 和 g2\_21 等核心网格展开。其中，g12\_1->g2\_21 为最高频流向，累计订单数为 942；g12\_1->g10\_1、g11\_0->g12\_1、g12\_1->g16\_2 和 g16\_2->g12\_1 也具有较高流量，说明核心区域之间

存在较稳定的出租车出行走廊。该结果表明，Porto 出租车需求并非均匀分布，而是集中在少数高频 OD 联系和大量低频 OD 对共同构成的长尾结构中。

（二）热点结果分析

表 7 展示了不同时间段的 OD 流量分布。OD 分析输出共包含 54856 条“时间段一起点网格—终点网格”记录，对应 29849 个不同 OD 对，累计订单数为 167043，与有效样本总量一致，说明订单级特征表与 OD 聚合结果在数量上保持一致。分时段来看，中午时段订单数为 44334，占 26.54%；晚高峰为 39515，占 23.66%；早高峰为 35980，占 21.54%；凌晨为 29359，占 17.58%；夜间为 17855，占 10.69%。该分布表明，Porto 出租车需求并非只集中于传统早晚通勤高峰，中午和平峰时段仍具有较强出行活跃度。

表 7 分时段 OD 流量分布

| 时间段          | 订单数   | 占比     | 解释                        |
|--------------|-------|--------|---------------------------|
| midday       | 44334 | 26.54% | 平峰/中午活动强，体现商业、服务和短途出行需求   |
| evening_peak | 39515 | 23.66% | 晚高峰具有明显通勤和回程特征            |
| morning_peak | 35980 | 21.54% | 早高峰体现居住区到办公区、枢纽区的方向性流动    |
| late_night   | 29359 | 17.58% | 凌晨需求仍较高，可能与夜间商业和机场/枢纽出行有关 |
| night        | 17855 | 10.69% | 夜间需求相对较低，但局部热点仍明显         |

图 4 展示了不同时间段的 OD 流向热力图。

结合图 4 和高频 OD 统计结果可以看出，高频 OD 呈现明显长尾分布。最高频流向为 g12\_1->g2\_21，累计 942 单；前 10 个 OD 对合计占 3.31%，前 50 个 OD 对合计占 9.43%。这说明少数核心走廊具有稳定需求，但大量低频 OD 共同构成出租车服务覆盖面。

由热点统计结果可以看出，上客热点总量排名前十的网格合计占全部上客量的44.30%，其中 g12\_1、g16\_2、g11\_1、g11\_0 和 g12\_2 是最核心的上客区域。相比之下，落客热点前十合计占 25.81%，集中程度低于上客热点。这说明出租车需求的产生位置更加集中，而目的地分布相对分散，符合出租车承担点到点弹性出行服务的特征。

从时段差异看，早高峰落客热点以 g2\_21、g10\_1 和 g16\_2 为主，体现明显目的地导向；中午和晚高峰则 g12\_1、g16\_2 等核心区域同时承担上客和落客功能；凌晨时段 g11\_1 的上客量达到 5370，是所有分时段热点中最高的单元，说明夜间或凌晨需求高度集中于少数区域。由此可见，OD 与热点输出不仅描述了流量规模，也揭示了城市功能空间在不同时间段中的角色转换。




图 4 分时段 OD 流向热力图

## 六、路网构建、边级统计与动态成本

### （一）OSM 路网与边级映射

路径优化以 OSM 可行驶路网为搜索空间。路网文件 porto\_drive.graphml 保存道路节点、道路边、边长、道路类型和自由流通行时间等信息。订单轨迹中的点列通过近

邻方式映射到道路边，得到每条订单可能经过的边序列。基于该映射，可以将订单级速度、距离、时段和上客位置转化为道路边统计结果。

边级统计输出是路径优化的核心输入。输出文件按道路边和时段聚合历史访问次数、平均速度、估计通行时间、拥堵指数、道路惩罚、风险指数和上客概率。与静态道路长度相比，边级统计同时包含历史运行状态和需求机会，更适合用于动态路径规划。

边级映射把订单轨迹从样本空间转化为道路空间。设第*i*条轨迹经近邻映射后得到边序列 $E_i = \{e_{i1}, e_{i2}, \dots, e_{im_i}\}$ ，则时间段 $r$ 内边 $e$ 的历史访问次数定义为：

$$N_e^{(r)} = \sum_{i=1}^N \mathbf{1}\{e \in E_i, t_i \in r\}.$$

若将边序列中的第一条边视为该订单的上客起始边，则上客起始次数为：

$$N_{e,+}^{(r)} = \sum_{i=1}^N \mathbf{1}\{e = e_{i1}, t_i \in r\}.$$

由此得到边级上客概率：

$$p_e^+(r) = \frac{N_{e,+}^{(r)}}{N_e^{(r)} + \varepsilon}.$$

该概率并非静态地理属性，而是由历史轨迹访问和订单起点共同估计得到的需求机会变量。它使司机视角下的路径选择能够把“经过哪里更可能接近下一单”纳入目标函数。

边级速度和通行时间进一步定义为：

$$\bar{v}_e^{(r)} = \frac{1}{N_e^{(r)} + \varepsilon} \sum_{i: e \in E_i, t_i \in r} v_i, \\ \tau_e^{(r)} = 3.6 \frac{\ell_e}{\bar{v}_e^{(r)} + \varepsilon}.$$

其中 $\ell_e$ 为道路边长度。若 $\tau_e^0$ 表示自由流通行时间，则拥堵指数与风险指数为：

$$q_e^{(r)} = \frac{\tau_e^{(r)}}{\tau_e^0 + \varepsilon}, \quad r_e^{(r)} = \max(q_e^{(r)} - 1, 0) + g_e.$$

上述定义将历史速度、道路等级和拥堵变化统一到边级统计框架中，使动态路径规划能够摆脱仅依赖静态长度的限制。

当前 `edge_stats.csv` 包含 34,577 条“道路边一时间段”记录，覆盖 10,269 条唯一道路边；边访问次数合计 494,709，约为订单总量的 2.96 倍；边级上客次数合计 167,043，与订单总量一致。详细数据由表 8 所示。

表 8 分时段边级统计结果

| 时间段             | 边-时段<br>记录数 | 边访问<br>次数 | 上客次<br>数 | 平均速度<br>(km/h) | 平均拥<br>堵指数 | 解释                    |
|-----------------|-------------|-----------|----------|----------------|------------|-----------------------|
| Midday          | 7629        | 131,328   | 44,334   | 28.29          | 1.77       | 访问量最高，说明中<br>午出行活跃    |
| Evening<br>Peak | 7527        | 117,167   | 39,515   | 25.80          | 1.93       | 速度最低、拥堵最<br>高，符合晚高峰特征 |
| Morning<br>Peak | 7243        | 106,470   | 35,980   | 28.61          | 1.76       | 流量明显但速度略高<br>于晚高峰     |
| Late<br>Night   | 6703        | 86,805    | 29,359   | 33.42          | 1.47       | 速度最高、拥堵最<br>低，路网更顺畅   |
| Night           | 5475        | 52,939    | 17,855   | 29.20          | 1.70       | 需求与访问量最低，<br>但仍存在局部热点 |

图 5 给出了边级拥堵指数的空间分布，图 6 给出了上客概率的空间分布，二者分别反映道路通行状态和潜在需求机会。




图 5 边级拥堵指数图

道路等级分布显示，secondary、residential、tertiary 和 primary 道路承担了大部分轨迹访问。其中 secondary 道路访问次数为 170,553，residential 道路访问次数为

134,981。这说明出租车不仅依赖主干路，也大量进入居住区和次级道路完成上客与送客，因此路径成本必须同时考虑道路等级、拥堵和上客机会。




图 6 上客概率空间分布

由图 5、图 6 可以看出，拥堵指数和上客概率在空间上呈现差异化分布：部分中心区域和高频通行道路具有较高拥堵水平，而上客概率则集中在少数具有稳定需求的道路边附近。边级上客概率具有明显稀疏性，平均值为 0.225，中位数为 0.038，75%分位数为 0.333，95%分位数达到 1.000。这意味着少数道路边具有很高的上客集中度，但低访问次数边可能出现概率虚高，因此司机侧路径优化不能仅依赖上客概率单一指标。

## （二）乘客视角与司机视角的复合成本

乘客视角的路径目标强调通行效率、稳定性和风险控制，因此复合成本由基础通行代价和环境放大项组成。基础通行代价综合距离、历史通行时间、道路属性和风险，环境放大项进一步考虑拥堵强度和 demand 机会差异。该形式能够避免只用距离或时间造成的片面性，使路径在较短、较快和较稳定之间取得平衡。

为消除量纲差异，任一边级变量  $z_e$  在参与成本函数之前采用最小—最大归一化：

$$\tilde{z}_e = \frac{z_e - \min_{e \in E} z_e}{\max_{e \in E} z_e - \min_{e \in E} z_e + \varepsilon}. \quad (17)$$

在乘客视角下，复合成本分为基础代价和环境放大项。基础代价为：

$$B_e^{(r)} = \alpha \tilde{\ell}_e + \beta \tilde{\tau}_e^{(r)} + \gamma \tilde{g}_e + \delta \tilde{r}_e^{(r)}, \quad (18)$$

环境放大项为：

$$M_e^{(r)} = 1 + \lambda_1 \tilde{q}_e^{(r)} + \lambda_2 (1 - p_e^+(r)). \quad (19)$$

乘客侧最终边成本为：

$$C_{e,p}^{(r)} = B_e^{(r)} M_e^{(r)} + \varepsilon. \quad (20)$$

该结构的含义在于：距离、时间、道路等级和风险构成边本身的基础消耗；拥堵和需求机会以乘法形式修正基础消耗。当道路拥堵显著时，原本较长或风险较高的道路会被进一步放大；当道路本身成本较低时，环境项对总成本的影响相对有限。由此，成本函数既保持线性可解释性，又允许拥堵环境产生非线性放大效应。

司机视角先定义收益函数：

$$U_e^{(r)} = \omega_1 p_e^+(r) - \omega_2 \tilde{t}_e^{(r)} - \omega_3 \tilde{q}_e^{(r)} - \omega_4 \tilde{\ell}_e. \quad (21)$$

由于最短路搜索要求非负边权，收益需要转化为成本。令  $\tilde{U}_e^{(r)}$  为归一化后的收益，则司机侧成本为：

$$C_{e,d}^{(r)} = 1 - \tilde{U}_e^{(r)} + \rho \tilde{\ell}_e + \varepsilon. \quad (22)$$

上式中，上客概率越高，司机侧收益越高、转化成本越低；通行时间、拥堵强度和空驶距离越大，收益越低、转化成本越高。这一处理使司机收益最大化问题能够转化为图上的最小成本路径问题。

司机视角的路径目标更关注接单机会和空驶成本。由于常规最短路搜索需要非负边成本，司机侧收益被转化为可搜索的最小化成本：上客概率越高，成本越低；通行时间、拥堵程度和空驶距离越高，成本越高。该处理保证了 Dijkstra 或 A\* 等图搜索方法能够使用，同时保留司机侧收益最大化的含义。

在路径层面，乘客视角与司机视角的最优路径分别表示为

$$\begin{aligned} P_p^* &= \arg \min_{P \in \mathcal{P}(o,d)} \sum_{e \in P} C_{e,p}^{(r)}, \\ P_d^* &= \arg \min_{P \in \mathcal{P}(o,d)} \sum_{e \in P} C_{e,d}^{(r)}. \end{aligned} \quad (23)$$

若直接采用司机收益最大化形式，也可写为

$$P_d^* = \arg \max_{P \in \mathcal{P}(o,d)} \sum_{e \in P} U_e^{(r)}. \quad (24)$$

两种写法本质一致：前者适用于非负边权最短路搜索，后者保留司机收益最大化的经济含义。Dijkstra 方法在非负边权下保证最优性；A\*方法可进一步引入启发式函数 $h(v)$ ，其搜索优先级为

$$F(v) = G(v) + h(v), \tag{25}$$

其中 $G(v)$ 表示从起点到当前节点的累计成本， $h(v)$ 表示从当前节点到终点的剩余成本估计。当 $h(v)$ 不高估真实剩余成本时，A\*能在保持最优性的同时减少无效搜索。

七、路径规划输出与对比分析

表 9 乘客视角与司机视角路径

| 路径<br>视角 | 时段           | 节<br>点<br>数 | 路径长度<br>(m)        | 自由流时间<br>(s)       | 综合成<br>本 | 解释              |
|----------|--------------|-------------|--------------------|--------------------|----------|-----------------|
| 乘客<br>视角 | morning_peak | 33          | 2789.25            | 216.38             | 100.17   | 强调到达效率、稳定性和少绕行  |
| 司机<br>视角 | morning_peak | 28          | 3059.83            | 242.62             | 110.34   | 兼顾通行成本与潜在接单机会   |
| 差异       | -            | -           | +270.58<br>(9.70%) | +26.24<br>(12.13%) | -        | 司机路径为提高机会接受一定绕行 |

路径规划结果以 passenger\_route.geojson、driver\_route.geojson 及对应的元信息文件为主要输出形式。GeoJSON 文件用于保存路线几何信息，便于在地图上展示乘客视角与司机视角下的路径差异；元信息文件则记录路径目标、出发时段、起终点节点、路径节点数、综合成本、路径长度以及自由流通行时间等指标，从而为路径优劣比较提供量化依据。乘客视角与司机视角虽然使用相同的 OSM 路网和边级统计信息，但由于目标函数不同，最终得到的最优路径并不一致，这也说明复合成本设计能够将“通行效率最优”和“接单收益最优”区分开来，并在统一图搜索框架下分别加以表达。

表 9 展示出乘客视角与司机视角的路径对比，图 7 展示不同视角下的路径规划路线，其中蓝色为乘客视角，红色为司机视角。



图 7 乘客视角与司机视角路径对比图

从表 9 和图 7 可以看出，两类路径在城市路网中的走向存在明显差异。司机视角路径比乘客视角路径略长、自由流时间略高，但它体现了对上客机会的偏好。该差异说明，复合成本并非简单追求单一指标的绝对最小，而是在几何距离、历史通行效率、拥堵水平和需求机会之间形成可解释权衡。

总而言之，乘客视角关注的是“尽快、平稳、少绕行”地到达目的地，而司机视角更关注“在可接受通行成本内获取更高的需求机会”。这种差异表明，同一 OD 查询下，乘客与司机对路径的偏好并不完全一致，路径结果的分离具有明确的交通含义和现实解释。

## 八、结论与展望

本文围绕 Porto 出租车轨迹数据构建了出行模式识别与动态路径优化一体化模型。通过轨迹解析、异常清洗、时间转换和网格化处理，原始订单被转化为包含时间、空间、轨迹几何和热点关系的特征表；通过 XGBoost 行为识别模型和 SHAP 解释输出，

出租车上客方式和出行类型能够被识别并解释；通过 OD 矩阵和热点统计，城市出租车需求结构能够被量化；通过边级历史速度、拥堵指数、道路风险和上客概率，统计结果能够进一步进入道路网络并形成动态成本；通过乘客视角和司机视角路径规划，模型最终完成从轨迹数据理解到路径决策支持的闭环。

研究结果说明，出租车行为模式具有显著的时间节律和空间集聚特征。在行为识别模型中，起点网格、出发小时、转向次数、行程时长、绕行程度、平均速度和行程距离是影响识别结果的重要因素；OD 频率和热点强度则主要用于解释需求结构并支撑后续路径优化。OD 结果揭示了城市内部稳定需求走廊，边级统计结果刻画了道路通行状态和上客机会，路径结果表明复合成本能够在通行效率、拥堵规避和需求收益之间实现更均衡的选择。该框架不仅适用于单次路径推荐，也可服务于出租车运力投放、热点巡游和交通管理评价。

本文仍存在扩展空间。首先，当前道路映射采用近邻方式，复杂路口和高架道路场景下仍可能产生偏差，后续可引入更精细的轨迹匹配模型。其次，动态成本主要依赖历史轨迹统计，实时交通信息、天气信息和特殊事件尚未纳入。再次，司机侧收益以道路上客概率近似表达，未来可结合订单等待时间、空驶距离和区域供需比进一步细化。最后，路径优化当前以单车单次查询为主，若扩展至全局车辆调度，还需要考虑多车辆协同和区域供需平衡。

总体而言，本文形成了较完整的统计建模链条：数据处理保证样本质量，行为识别刻画出行模式，模型解释揭示影响机制，OD 分析刻画需求结构，道路边统计承接历史经验，路径规划输出可视化路线和量化指标。该链条能够将出租车轨迹数据转化为可解释、可复核、可用于决策的模型结果，为智慧城市交通治理提供具有应用价值的分析框架。

## 参考文献

- [1] 李德仁, 邵振峰. 智慧城市中的时空大数据与城市治理[J]. 武汉大学学报信息科学版, 2018, 43(12): 1817-1824.
- [2] Ge Y, Xiong H, Tuzhilin A, et al. An energy-efficient mobile recommender system[C]. Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2010: 899-908.
- [3] Yuan J, Zheng Y, Xie X, et al. Driving with knowledge from the physical world[C]. Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2011: 316-324.
- [4] Yuan J, Zheng Y, Zhang C, et al. T-drive: Driving directions based on taxi trajectories[C]. Proceedings of the 18th SIGSPATIAL International Conference on Advances in Geographic Information Systems, 2010: 99-108.
- [5] Zheng Y. Trajectory data mining: an overview[J]. ACM Transactions on Intelligent Systems and Technology, 2015, 6(3): 1-41.
- [6] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794.
- [7] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. Advances in Neural Information Processing Systems, 2017: 4765-4774.
- [8] Lundberg S M, Erion G, Chen H, et al. From local explanations to global understanding with explainable AI for trees[J]. Nature Machine Intelligence, 2020, 2(1): 56-67.
- [9] Boeing G. OSMnx: New methods for acquiring, constructing, analyzing, and visualizing complex street networks[J]. Computers, Environment and Urban Systems, 2017, 65: 126-139.
- [10] Dijkstra E W. A note on two problems in connexion with graphs[J]. Numerische Mathematik, 1959, 1: 269-271.
- [11] Hart P E, Nilsson N J, Raphael B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE Transactions on Systems Science and Cybernetics, 1968, 4(2): 100-107.

- [12] Lou Y, Zhang C, Zheng Y, et al. Map-matching for low-sampling-rate GPS trajectories[C]. Proceedings of the 17th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, 2009: 352-361.
- [13] Newson P, Krumm J. Hidden Markov map matching through noise and sparseness[C]. Proceedings of the 17th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems, 2009: 336-343.
- [14] Castro P S, Zhang D, Li S. Urban traffic modelling and prediction using large scale taxi GPS traces[C]. Pervasive Computing, 2012: 57-72.
- [15] Li B, Zhang D, Sun L, et al. Hunting or waiting? Discovering passenger-finding strategies from a large-scale real-world taxi dataset[C]. IEEE International Conference on Pervasive Computing and Communications Workshops, 2011: 63-68.
- [16] Qu M, Zhu H, Liu J, et al. A cost-effective recommender system for taxi drivers[C]. Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2014: 45-54.
- [17] Gonzalez M C, Hidalgo C A, Barabasi A L. Understanding individual human mobility patterns[J]. Nature, 2008, 453(7196): 779-782.
- [18] Song C, Qu Z, Blumm N, et al. Limits of predictability in human mobility[J]. Science, 2010, 327(5968): 1018-1021.
- [19] Hunter J D. Matplotlib: A 2D graphics environment[J]. Computing in Science & Engineering, 2007, 9(3): 90-95.
- [20] Moreira-Matias L, Gama J, Ferreira M, et al. Predicting taxi-passenger demand using streaming data[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(3): 1393-1402.